Prelucrarea datelor cu tehnici de Data Mining

Cuprins



- Ce este data mining
- Etapele procesului de data mining
- Metode si subdomenii in data mining
- Preprocesarea datelor
- Sumar

Definitie ([Liu 11])

- Data mining este cunoscut si sub numele KDD - Knowledge Discovery in Databases (descoperirea de cunostinte in date).
- In mod obisnuit este definit ca procesul de descoperire a unor sabloane/modele (eng. patterns) / cunostinte utile in diverse surse de date: baze de date, colectii de texte, de imagini sau de pagini web, etc.
- Sabloanele trebuie sa fie valide, utile si inteligibile.

Definitie ([Ullman 09, 10])

- Descoperirea de sabloane utile, uneori neasteptate, in date.
- Descoperirea de "modele" pentru date prin tehnici de tipul:
  - Modelare statistica
  - Invatare automata (Machine learning)
  - Abordari computationale in modelare
  - Sumarizare
  - Extragerea proprietatilor (Feature Extraction)

Definitie ([Wikipedia])

- Data mining (etapa de analiza a procesului KDD - knowledge discovery in databases) este procesul de descoperire de noi sabloane in seturi mari de date prin metode aflate la intersectia dintre inteligenta artificiala, invatarea automata, statistica si baze de date.
- Obiectivul procesului de data mining este acela de a extrage cunostinte dintr-un set de date intr-o forma inteligibila pentru utilizatorii umani.
- Procesul implica baze de date si gestiunea informatiei, preprocesarea datelor, probleme de modelare si inferenta, metrici pentru performanta rezultatelor, probleme de complexitate, post procesare si vizualizare.

Definitie ([Kimball, Ross 02])

- O categorie de cereri executate adesea pe datele atomice pentru a gasi sabloane/modele neasteptate in date.
- Cele mai cunoscute subdomenii ale data mining sunt clasificarea, gruparea (clustering), estimarea, predictia si gasirea evenimentelor care apar impreuna.
- Exista multe tipuri de unelte pentru data mining. Cele mai cunoscute sunt arborii de decizie, retelele neurale, unelte pentru vizualizarea seturilor de date, algoritmi genetici, logica fuzzy si unelte folosite in statistica obisnuita.
- In cazul aplicatiilor concrete pentru mediul economic data mining foloseste de obicei date aflate intr-un depozit de date (data warehouse).

Concluzii

- Procesul de data mining converteste datele in cunostinte valoroase care pot fi folosite pentru suportul deciziei.
- Domeniul Data mining consta intr-o colectie de metodologii de analiza a datelor, tehnici si algoritmi pentru descoperirea de noi sabloane.
- Data mining se foloseste cu precadere pentru seturi mari de date.
- Procesul de data mining este automat (nu necesita interventie umana).
- Data mining si Knowledge Discovery in Databases (KDD) sunt considerate de multi autori ca fiind acelasi lucru dar exista autori pentru care care data mining este doar etapa de analiza si de extragere a sabloanelor a procesului de descoperire a cunostintelor in date (KDD), etapa care se desfasoara dupa curatarea si transformarea datelor si inainte de vizualizarea si evaluarea rezultatelor.

Exemple de succes

In cursurile profesorului J. Ullman de la Stanford sunt enumerate cateva exemple de succes ale folosirii tehnicilor de data mining (preluare din [Ullman 03]):

- Arbori de decizie construiti din istoria imprumuturilor bancare pentru a genera algoritmi de acordare a imprumuturilor.
- Sabloane ale comportamentului calatorilor pentru a optimiza vanzarea cu pret redus a locurilor la avion sau a camerelor de hotel.
- “Scutece si bere" S-a observat ca cei care cumpara scutece sunt mai inclinati decat ceilalti sa cumpere bere. Datorita acestui rezultat, cele doua produse se pot plasa intr-un supermarket unul in apropierea celuilalt, astfel incat multi cumparatori vor circula intre cele doua raioane. Plasarea cipsurile pe traseu a dus la cresterea vanzarilor pentru toate cele 3 produse.

Exemple de succes

- Skycat si Sloan Sky Survey: gruparea obiectelor ceresti dupa nivelele radiatiei electromagnetice intr-un numar de benzi de frecventa a permis identificarea galaxiilor, stelelor apropiate si a altor categorii de obiecte celeste.
- Compararea genotipului persoanelor avand sau neavand o anumita problema de sanatate a permis descoperirea unor gene care sunt asociate cu respectiva problema (de exemplu diabet). In acest fel se pot lua masuri de prevenire inainte de declansarea bolii in cazul persoanelor care prezinta respectivele caracteristici.

Ce NU este Data Mining:

- Cautarea unei persoane in baza de date a unei organizatii.
- Calcularea de valori minime, maxime, medii, sume sau numararea valorilor aflate in tabelele unei baze de date (operatii pur statistice).
- Folosirea unui motor de cautare pentru a gasi referintele asociate numelui tau.

Date, informatii, cunostinte

- Să zicem că ai un magazin şi înregistrezi toate detaliile clienților tai în baza de date a acestuia. Ştii numele clienților şi produsele pe care le cumpără în fiecare zi.
- De exemplu, Alex, Jessica şi Paul vizitează magazinul tau în fiecare duminică şi cumpără lumânări. Stochezi aceste informații în aplicatia informatica a magazinului. Acestea sunt date. Ori de câte ori doresti să afli cine sunt clienții care cumpără lumânări, poți interoga baza de date şi primesti răspunsul. Acesta este o informație. Dacă vrei să ştii câte lumânări sunt vândute în fiecare zi din săptămână în magazinul tău, poți să interoghezi din nou baza de date şi vei primi răspunsul - aceasta este o altă informație.
- Să presupunem că există şi alți 1000 de clienți care, de asemenea, cumpără lumânări de la tine în fiecare duminică (majoritatea - cu un anumit procent de variație) şi toți aceştia sunt creştini prin religie. Deci, poți concluziona că Alex, Jessica şi Paul trebuie să fie şi ei creştini.

Sursa: http://www.dwbiconcepts.com/data-warehousing/11-data-mining/97-data-mining-for-beginners.html

Date, informatii, cunostinte

- Acum, religia lui Alex, a lui Jessica şi a lui Pavel nu o ai ca date in datele stocate. Acest lucru nu poate fi regăsit din baza de date ca informație. Dar ai obținut indirect această informație. Aceasta este o "cunoştință" pe care ai descoperit-o. Şi această descoperire a fost făcută printr-un proces numit "Data Mining".
- ***Există şanse să te înşeli în legătură cu Alex, Jessica şi Paul***. Dar există o mulțime de şanse să ai dreptate. De aceea este foarte important să "***evaluăm***" rezultatul procesului de Data Mining.
- Am dat acest exemplu pentru că am vrut să fac o distincție clară între cunoştințe şi informații în contextul domeniului Data Mining. Este important de înțeles. . . de ce **regăsirea informațiilor** de oriunde s-ar afla in baza de date ***nu este acelasi lucru cu Data Mining***. Indiferent cât de complex este procesul de regăsire a informației, indiferent cât de adânc este localizată informația, asta nu este Data Mining.

Sursa: http://www.dwbiconcepts.com/data-warehousing/11-data-mining/97-data-mining-for-beginners.html

Software pentru DM

In lucrarea ([Mikut, Reischl 11]) programele software pentru data mining sunt clasificate in 9 categorii:

- **Suite pentru data mining** (Data mining suites -DMS) sunt pachete dedicate aplicatiilor de DM. Includ numeroase metode / algoritmi. Exemple:
  - Comerciale: IBM SPSS Modeler, SAS Enterprise Miner, DataEngine, GhostMiner, Knowledge Studio, NAG Data Mining Components, STATISTICA
  - Open source: RapidMiner
- **Pachete de Business intelligence** (Business intelligence packages - BIs) includ functionalitati de baza pentru DM - de exemplu metode statistice pentru aplicatii de business. Exemple:
  - Comerciale: IBM Cognos 8 BI, Oracle DataMining, SAPNetweaver Business Warehouse, Teradata Database, DB2 Data Warehouse from IBM
  - Open source: Pentaho

Software pentru DM

- **Pachete matematice** (Mathematical packages - MATs) contin o multime mare si extensibila de algoritmi precum si rutine de vizualizare. Exemple:
  - Comerciale: MATLAB, R-PLUS
  - Open source: R, Kepler
- **Pachete integratoare** (Integration packages - INTs) sunt colectii extensibile de algoritmi de tip open-source. Exemple:
  - Stand-alone software (KNIME, versiunea GUI pentru WEKA, KEEL, TANAGRA)
  - Extensii pentru uneltele de tip MAT descrise mai sus.
- **Extensii** (EXT) sunt accesorii (add-ons) pentru alte unelte ca Excel, Matlab, R, cu o functionalitate limitata dar utila in diverse cazuri. Exemple:
  - Retele neuronale pentru Excel (Forecaster XL, XLMiner)
  - MATLAB (Matlab Neural Networks Toolbox).

Software pentru DM

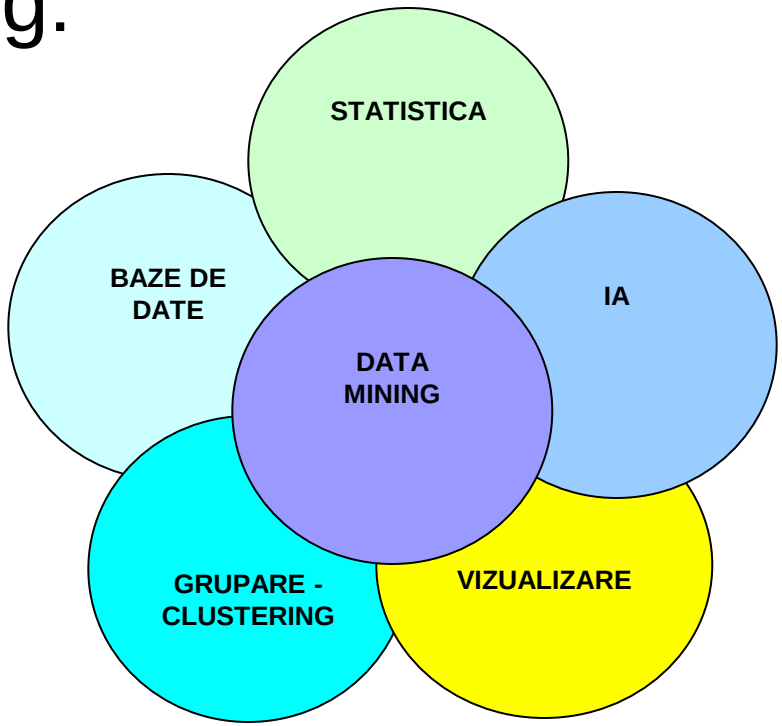
- **Biblioteci de DM** (Data mining libraries - LIBs) contin functii care pot fi folosite in alte unelte software. Exemple:

  Neurofusion for C++, WEKA, MLC++, JAVA Data Mining Package, LibSVM
- **Specialitati** (Specialties - SPECs) sunt similare cu DMS dar implementeaza doar o categorie/familie de metode. Exemple:

  CART, Bayesia Lab, C5.0, WizRule, Rule Discovery System, MagnumOpus, JavaNNS, Neuroshell, NeuralWorks Predict, RapAnalyst.
- **Cercetare** (Research - RES) sunt primele implementari ale unor noi algoritmi, avand de obicei un suport grafic restrans si fara foarte multe facilitati in utilizare. Sunt de obicei open source. WEKA si RapidMiner au debutat in aceasta categorie.
- **Solutii** (Solutions - SOLs) descriu unelte care sunt adaptate la un domeniu ingust de aplicatii. Exemple: pentru text mining: GATE; pentru prelucrare de imagini: ITK, ImageJ; cercetarea farmaceutica: Molegro Data Modeler

Comunitati implicate

Cele mai importante comunitati implicare in data mining:



Cuprins

- Ce este data mining
- Etapele procesului de data mining
- Metode si subdomenii in data mining
- Preprocesarea datelor
- Sumar

Etapele procesului de DM (1)

1. **Colectarea datelor**: Datele sunt culese din baze de date existente sau prin parcurgerea paginilor web (Web crawling).
2. **Preprocesarea datelor**, presupune mai multe activitati desfasurate in scopul pregatirii datelor pentru aplicarea algoritmilor specifici

Preprocesarea datelor

- Curatarea datelor (Data cleaning):
  - inlocuirea sau inlaturarea valorilor lipsa,
  - netezirea datelor care contin zgomot,
  - identificarea si eventual inlaturarea punctelor izolate (eng.: outliers - valori izolate, departate de toate celelalte),
  - inlaturarea inconsistentelor.

Nota: in multe documente termenul 'outliers' a fost tradus in limba romana prin 'valori aberante' - prin similitudine cu traducerea in limba franceza.

Preprocesarea datelor

- Integrarea datelor (Data integration):
  - integrarea intr-un corp unic a datelor provenite din mai multe surse,
  - Conversii de tip si de structura,
  - eliminarea duplicatelor,
  - tratarea inconsistentelor datorate integrarii.

Preprocesarea datelor

- Transformarea datelor (Data transformation):
  - normalizarea (sau standardizarea) datelor,
  - sumarizari,
  - generalizari,
  - constructia de noi atribute, etc.

Preprocesarea datelor

- Reducerea datelor (Data reduction): nu toate atributele existente sunt necesare pentru un anumit proces de data mining.
- Prin reducere se opresc doar acele atribute care sunt necesare diminuand astfel volumul de date prelucrate (si implicit timpul de rulare al algoritmului).

Preprocesarea datelor

- Distretizare: Anumiti algoritmi lucreaza doar pe date discrete. De aceea pentru atributele avand valori continue trebuie efectuata discretizarea constand in inlocuirea acestor valori cu altele dintr-o multime de valori discrete.
- De exemplu varsta se poate inlocui cu un atribut avand doar trei valori: Tanar, Adult si Batran.

Etapele procesului de DM (2)



3. **Extragerea sabloanelor si descoperirea de cunostinte**. Aceasta este etapa in care sunt efectiv utilizati algoritmii de DM pentru obtinerea rezultatului. Unii autori reduc domeniul Data Mining la aceasta etapa, intregul proces fiind numit KDD.
4. **Vizualizarea:** deoarece data mining extrage proprietati/informatii ascunse din date este necesara o vizualizare a rezultatelor pentru o mai buna intelegere a lor si pentru a le evalua. Vizualizarea este uneori necesara si pentru datele de intrare.

Etapele procesului de DM (3)



3. **Evaluarea rezultatului:** nu tot ce iese dintr-un proces de data mining este valoros.

- Unele rezultate sunt adevaruri pur statistice care se puteau deduce si fara aplicarea algoritmilor iar altele nu prezinta interes pentru utilizator.
- De aceea este necesara evaluarea rezultatelor de catre experti pentru a separa cunostintele valoroase de celelalte lucruri obtinute in urma rularii algoritmului.

Principiul lui Bonferroni

- O 'cunostinta' descoperita in urma procesului de data mining poate fi un adevar pur statistic. Exemplu (din [Ullman 03]):
- In 1950 David Rhine, un parapsiholog de la universitatea Duke a testat studentii pentru a afla daca au sau nu perceptie extrasenzoriala (ESP).
- Pentru asta le-a cerut sa ghiceasca culoarea a 10 carti de joc succesive - rosu sau negru. Rezultatul a fost ca 1/1000 din participanti au ghicit toate cele 10 carti - in consecinta el i-a declarat ca avand ESP.

Principiul lui Bonferroni

- Re-testarea efectuata doar asupra acestora nu a mai avut aceleasi rezultate, el considerand ca in momentul in care au aflat ca au ESP au pierdut aceasta capacitate.
- David Rhine nu a realizat ca statistica spune ca probabilitatea de a ghici 10 carti succesive este de $1/2^{10}$ = 1/1024 deoarece probabilitatea de a ghici o carte este 1/2 (rosu sau negru)!

Principiul lui Bonferroni

- Astfel de rezultate pot fi regasite in iesirea unui algoritm de data mining si trebuie recunoscute ca adevaruri statistice si nu ca rezultate reale ale procesului de data mining.
- Astfel de rezultate sunt obiectul principiului lui Bonferroni. Acesta poate fi sintetizat astfel:

Daca sunt prea multe concluzii, unele vor fi adevarate din motive pur statistice.

Data Mining, noun: ***"Torturing data until it confesses ... and if you torture it enough, it will confess to anything"*** - Jeff Jonas, IBM (http://www.cs.ccsu.edu/~markov/ccsu_courses/DataMining-1.html)

Cuprins



- Ce este data mining
- Etapele procesului de data mining
- Metode si subdomenii in data mining
- Preprocesarea datelor
- Sumar

2 tipuri de metode

- **Metode predictive:** Aceste metode utilizeaza anumite variabile pentru a prezice valoarea altor variabile. Un exemplu din aceasta categorie este clasificarea: bazat pe date cunoscute si deja etichetate (clasificate), algoritmii de clasificare creaza modele care pot fi folosite pentru clasificarea unor date noi, necunoscute.
- **Metode descriptive:** Algoritmii din aceasta categorie gasesc sabloane / modele care descriu structura interna a unui set de date. De exemplu algoritmii de grupare (clustering) gasesc grupuri de obiecte similare in setul de date (grupuri numite clustere) si de asemenea detecteaza posibile obiecte izolate, departate de oricare dintre clustere - asa numitii 'outliers'.

Algoritmi

- **Algoritmi de predictie:**
  - Clasificare
  - Regresie
  - Detectia deviatiei
- **Algoritmi de descriere:**
  - Grupare - Clustering
  - Gasirea de reguli de asociere
  - Descoperirea de sabloane secventiale

Clasificare



Intrare:

- Un set avand un numar k de clase C = $\{c_1, c_2, \ldots, c_k\}$
- Un set de ***n*** articole etichetate D = $\{(d_1, c_{i1}), (d_2, c_{i2}), \ldots, (d_n\ c_{in})\}$. Articolele sunt $d_1, \ldots, d_n$, fiecare articol d_j fiind etichetat cu clasa $c_{ij} \in C$. D este numit si setul (multimea) de **antrenare (training set).**
- Pentru calibrarea unor algoritmi este necesar si un set (multime) **de validare (validation set)**. Acesta contine de asemenea articole etichetate, neincluse in setul de antrenare

Iesire:

- Un model sau metoda de a clasifica noi articole (clasificator). Setul continand noile articole se numeste set **de test (test set)**

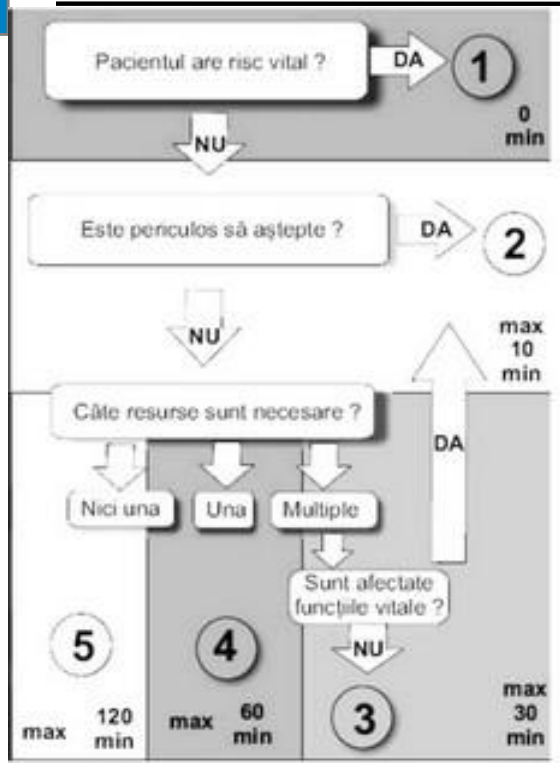
Exemplu

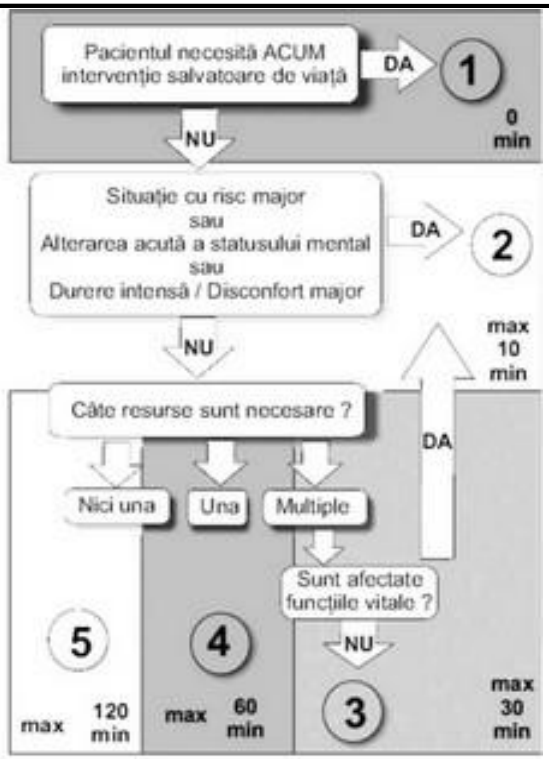
- Sa consideram ca articolele sunt pacienti ai unui serviciu de urgente medicale.
- Exista 5 clase, C_0, C_{10}, C_{30}, C_{60} si C_{120}, unde eticheta C_k inseamna ca pacientul poate fi lasat sa astepte maxim **k** minute fara ca starea sa se inrautateasca.
- Vom reprezenta datele setului de antrenare sub forma tabelara.
- Iesirea unui algoritm de creare a unui clasificator poate fi de exemplu un arbore de decizie sau un set ordonat de reguli.
- Modelul obtinut poate fi utilizat apoi pentru a clasifica noi pacienti asignandu-le o eticheta din multimea celor 5 de mai sus.

Multimea de antrenare UPU

Name (or ID)	Vital risk?	Danger if waits?	0 resource needed	1 resource needed	>1 resource needed	>1 resource needed and vital function s affected	Waiting time (class label)
John	Yes	Yes	No	Yes	No	No	C0
Maria	No	Yes	No	No	Yes	No	C10
Nadia	Yes	Yes	Yes	No	No	No	C0
Omar	No	No	No	No	Yes	Yes	C30
Kiril	No	No	No	Yes	No	Yes	C60
Denis	No	No	No	No	Yes	No	C10
Jean	No	No	Yes	Yes	No	No	C120
Patricia	Yes	Yes	No	No	Yes	Yes	C60

Rezultat: arbori de decizie





Pentru un nou pacient:

Felix	**Yes**	**Yes**	**No**	**No**	**No**	**Yes**	**?????**

arborele de decizie produce clasa C0

Regresia (1)

- Regresia provine din statistica.
- Inseamna: prezicerea (predictia) valorii unei anumite variabile continue pe baza valorilor altor variabile, considerand un model de dependenta liniara sau neliniara ([Tan, Steinbach, Kumar 06]).
- Utilizata in predictie si prognoza; este folosita si in domeniul invatarii automate.
- Analizele bazate pe regresie sunt folosite pentru intelegerea relatiilor dintre variabile dependente si independente.

Intrebare: care e deosebirea intre predictie si prognoza?

Regresia (2)



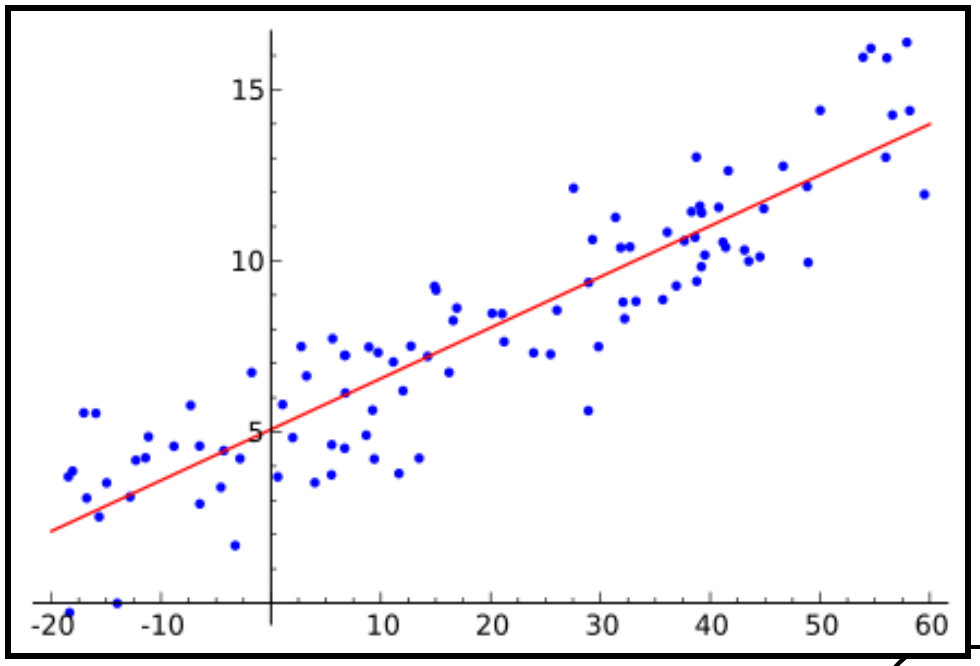
Exista multe tipuri de regresie, de exemplu:

- Regresie liniara
- Regresie liniara simpla
- Regresie logistica
- Regresie neliniara
- Regresie nonparametrica
- Regresie robusta

Exemplu

Exemplu de regresie liniara

(sursa: http://en.wikipedia.org/wiki/File:Linear_regression.svg)



Detectia deviatiei

- Detectia deviatiei (sau a anomaliilor) presupune descoperirea de deviatii semnificative de la comportamentul normal. Punctele izolate (outliers) sunt o categorie semnificativa de astfel de date anormale.
- Detectia deviatiei poate fi utilizata in multe situatii:
  - In faza de rulare a algoritmului de data mining, datele anormale putand avea un efect puternic asupra algoritmului
  - Audit: astfel de informatii pot arata existenta unor probleme sau practici gresite
  - Detectia fraudelor: cererile frauduloase contin deseori informatii inconsistente
  - Detectia intruziunilor intr-o retea de calculatoare poate fi facuta si pe baza unor date anormale
  - Curatarea datelor (data cleaning): astfel de informatii anormale pot reprezenta date eronate care trebuie corectate

Metode de detectie a deviatiei

- Tehnici bazate pe distante (ex. : k-nearest neighbor).
- Folosirea "One Class Support Vector Machines" (Ca un SVM clasic dar toate exemplele de antrenare sunt din aceeasi clasa si doar originea reprezinta cea de-a doua clasa).
- Metode predictive (arbori de decizie, retele neuronale).
- Detectia punctelor izolate folosind clustering.
- Inregistrari care nu respecta regulile de asociere
- Analize Hotspot (clustere avand o valoare ridicata a anumitor parametri; de exemplu politia foloseste astfel de analize pentru analiza zonelor unde criminalitatea are valori ridicate)

Algoritmi

- **Algoritmi de predictie:**
  - Clasificare
  - Regresie
  - Detectia deviatiei
- **Algoritmi de descriere:**
  - Grupare - Clustering
  - Gasirea de reguli de asociere
  - Descoperirea de sabloane secventiale

Clustering



Intrare:

- Un set de obiecte D = {d_1, d_2, …, d_n} (numite uzual puncte). Obiectele nu sunt etichetate si nu exista definit vreun set de clase.
- O functie de distanta (masura a disimilaritatii) care poate fi utilizata pentru a calcula distanta dintre oricare doua puncte. O distanta mica inseamna "aproape" iar una mare "departe".
- Unii algoritmi necesita introducerea unei valori pentru numarul de clustere de obtinut.

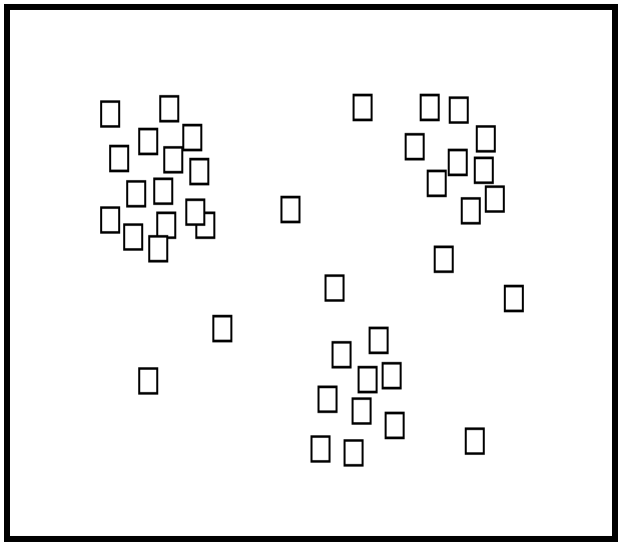
Iesire:

- Un set de grupuri de obiecte/puncte, numite clustere unde punctele din acelasi cluster sunt 'apropiate' iar cele din clustere diferite 'departate' unele de altele, considerand functia de distanta existenta.

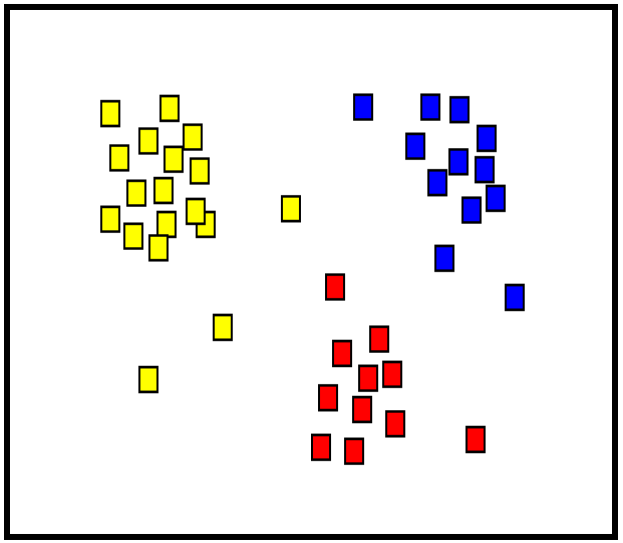
Exemplu

- Daca avem un set de 2 puncte intr-un spatiu 2D, sa se gaseasca grupurile/clusterele naturale formate de ele

INITIAL



DUPA CLUSTERING



Sursa: http://en.wikipedia.org/wiki/File:Cluster-1.svg, http://en.wikipedia.org/wiki/File:Cluster-2.svg

Reguli de asociere



Intrare:

- Un set de **m** articole I = {i_1, i_2, …, i_m}.
- Un set de **n** tranzactii T = { t_1, t_2, …, t_n}, fiecare tranzactie continand un subset al lui I. Deci daca $t_k \in T$ atunci t_k = {i_{k1}, i_{k2}, …, i_{kj}} unde j depinde de k (tranzactiile au lungimi diferite).
- Un prag s numit prag de suport, dat fie in procente fie in valoare absoluta. Daca o multime de articole (itemset) $X \in I$ este inclusa in w tranzactii atunci w este suportul lui X. Daca w >= s atunci X este numita multime frecventa de articole.
- Un al doilea prag c pentru increderea regulilor obtinute.

Iesire:

- Multimile frecvente de articole din T, avand suportul >= s
- Multimea de reguli derivate din T avand suportul >= s si increderea >= c

Reguli de asociere



- O **regula** este o constructie de tipul $X \rightarrow Y$ unde X si Y sunt multimi de articole (itemsets).
- **Suportul** unei reguli $X \rightarrow Y$ este numarul de aparitii ale $X \cup Y$ in T (egal cu suportul acestei reuniuni ca itemset):

$$\mathbf{support(X \rightarrow Y) = support(X \cup Y)}$$

- **Increderea** unei reguli este proportia tranzactiilor continandu-l pe Y in multimea tranzactiilor continandu-l pe X:

$$\mathbf{confidence(X \rightarrow Y) = support(X \cup Y) \,/\, support(X)}$$

- Acceptam o regula ca valida doar daca suportul si increderea ei sunt mai mari sau egale cu pragurile date.

Exemplu

- Sa consideram urmatorul set de tranzactii:

Transaction ID	Items
1	Bread, Milk, Butter, Orange Juice, Onion, Beer
2	Bread, Milk, Butter, Onion, Garlic, Beer, Orange Juice, Shirt, Pen, Ink, Baby diapers
3	Milk, Butter, Onion, Garlic, Beer
4	Orange Juice, Shirt, Shoes, Bread, Milk
5	Butter, Onion, Garlic, Beer, Orange Juice

- Daca s = 60% atunci {Bread, Milk, Orange Juice} sau {Onion, Garlick, Beer} sunt multimi frecvente de articole.
- De asemenea, daca s = 60%, c=70% atunci regula {Onion, Beer} $\rightarrow$ {Garlic} e valida avand suport de 60% si incredere de 75%.

Descoperire sabloane secventiale



Intrare:

- O multime de **m** articole I = {i_1, i_2, …, i_m}. O secventa este o lista ordonata de multimi de articole din I.
- O multime de secvente **S** (numita si 'sequence database').
- O functie booleana care poate testa daca o secventa S_1 este inclusa (este o subsecventa) in secventa S_2. In acest caz S_2 este numita o supersecventa a lui S_1.
- Un prag **s** (procent sau valoare absoluta) necesar pentru a gasi secvente frecvente.

Iesire:

- Multimea de secvente frecvente, i.e. multinea de secvente incluse in cel putin **s** secvente din S.
- Uneori se poate obtine si un set de reguli, fiecare regula fiind de forma $S_1 \rightarrow S_2$ unde S_1 si S_2 sunt secvente.

Exemplu



- Intr-o librarie putem gasi secvente ca:

  {Book_on_C, Book_on_C++, Book_on_Perl}

- Din aceasta secventa se poate deriva o regula de tipul: dupa cumpararea unor carti de C si C++, clientul cumpara carti de Perl:

  Book_on_C, Book_on_C++ → Book_on_Perl

Cuprins



- Ce este data mining
- Etapele procesului de data mining
- Metode si subdomenii in data mining
- Preprocesarea datelor
- Sumar

Preprocesarea datelor



- Tipuri de date
- Masurarea datelor
- Curatarea datelor
- Integrarea datelor
- Transformarea datelor
- Reducerea datelor
- Discretizarea datelor

Tipuri de date



- Categorice vs. Numerice
- Scale de masurare
  - Nominala
  - Ordinala
  - Interval
  - Proportionala (eng.: ratio scale)

Date categorice si numerice

- **Datele categorice** constau in nume reprezentând categorii. Exemple: culoare (cu categoriile roşu, verde, albastru si alb) sau gen (masculin, feminin)
- Valorile de acest tip nu sunt de obicei ordonate (nu exista o relație de ordine intre ele), operațiile posibile fiind testul de egalitate sau de apartenenta (incluziune) la o mulțime.

Date categorice si numerice

- **Datele numerice** constau in numere aparținând unei mulțimi continue sau discrete de valori numerice.
- Valorile sunt ordonate, astfel incat se poate testa ordinea (<, <=, >, >=).
- Uneori este necesara conversia datelor categorice in date numerice asignând o valoare numerica (sau cod) pentru fiecare eticheta (categorie).

Scale de masurare

- Stanley Smith Stevens, directorul laboratorului de psiho-acustica de la Universitatea Harvard a afirmat intr-un articol publicat in 1946 in revista Science ca toate masuratorile din stiinta utilizeaza patru tipuri diferite de scale de masurare:
  - Nominala
  - Ordinala
  - Interval
  - Proportionala (ratio scale)

Nominala

- Valorile apartinand scalei nominale sunt caracterizate prin etichete (nume).
- Valorile sunt neordonate si au importanta (pondere) egala.
- Nu putem calcula valoarea medie sau mediana a unui astfel de set.
- Putem totusi calcula valoarea modala – valoarea cea mai frecventa.
- Datele nominale sunt de tip categoric si uneori este nevoie sa fie convertite in valori numerice.

Ordinala

- Valorile de acest tip sunt ordonate dar diferenta / distanta intre doua valori nu poate fi calculata.
- Putem specifica doar ordinea / pozitia in sirul ordonat pentru aceste valori.
- Exemplu: lista gradelor militare, lista gradelor didactice, lista in ordinea sosirii a concurentilor la o cursa sportiva (doar lista numelor, fara timpii de sosire), etc.
- Pentru astfel de valori putem calcula valoarea modala si mediana (valoarea mijlocie) dar nu media.
- Valorile sunt in esenta categorice dar este mai usor sa le asignam valori numerice in caz de conversie.

Interval



- Aceste valori sunt numerice.
- In acest caz diferenta intre doua valori are semnificatie.
- Exemplu: temperatura in grade Celsius: diferenta intre 10 si 20 de grade este aceeasi ca cea intre 40 si 50 de grade (aceeasi cantitate de energie in cazul incalzirii unui corp).
- Valoarea zero (0) nu inseamna 'nimic' ci este o valoare arbitrar aleasa. De aceea sunt permise si valori negative
- Putem calcula media, mediana, valoarea modala, deviatia standard si putem utiliza regresia pentru a prognoza noi valori.

Proportionala (ratio)



- Aceste valori sunt numerice, ca si in cazul Interval, dar zero (0) inseamna 'Nimic'.
- Valorile negative nu au sens.
- Raportul dintre doua valori are semnificatie.
- Exemplu: greutatea in kg. Un corp de 10 kg este de doua ori mai greu decat unul de 5 kg.
- Alte exemple: temperatura in grade Kelvin, lungimea in metri, varsta in ani, etc.
- Toate operatiile matematice sunt permise.

Date binare

- Uneori un atribut poate avea doar 2 valori: 0 sau 1, masculin sau feminin, da sau nu, etc. In acest caz datele se numesc **binare**. Avem doua cazuri:

1. Binare simetrice: cele doua valori au importanta/ pondere egala (ca in cazul genului).
2. Binare asimetrice: una dintre valori are o importanta mai mare decat cealalta. De exemplu in cazul unei analize pentru depistarea HIV valoarea Pozitiv are o greutate mai mare decat Negativ.

Date binare

- Atributele binare pot fi tratate uneori ca fiind de tip interval sau proportional dar in cea mai mare parte a cazurilor ele vor fi considerate nominale (cele binare simetrice) sau ordinale (cele binare asimetrice).
- Exista o serie de functii de distanta (disimilaritate) care pot fi utilizate in acest caz.

Preprocesarea datelor

- Tipuri de date
- Masurarea datelor
- Curatarea datelor
- Integrarea datelor
- Transformarea datelor
- Reducerea datelor
- Discretizarea datelor

Masurarea datelor

- Masurarea tendintei/valorii centrale:
  - Medie
  - Mediana
  - Valoare modala
  - Mijlocul intervalului
- Masurarea dispersiei:
  - Interval de valori
  - Procentul k
  - IQR
  - Sumarul de 5 numere
  - Deviatia standard si varianta

Tendinta centrala - Medie

- Fie n valori ale unui atribut: $x_1, x_2, \ldots, x_n$.
- **Medie: Media aritmetica** sau valoarea medie este:

$$\mu = (x_1 + x_2 + \ldots + x_n) / n$$

- Daca valorile lui x au ponderile $w_1, \ldots, w_n$, atunci **media aritmetica ponderata** este:

$$\mu = (w_1x_1 + w_2x_2 + \ldots + w_nx_n) / (w_1 + w_2 + \ldots + w_n)$$

- In unele cazuri se practica eliminarea celor mai mici si celor mai mari valori (de exemplu cele mai mici 1% si cele mai mari 1%).

Tendinta centrala - Mediana



- **Mediana**: Valoarea mediana a unui set de **n** valori ordonate este valoarea din mijlocul secventei de valori.
- Exemplu: Mediana pentru {1, 3, 5, 7, 1001, 2002, 9999} is 7.
- Daca n este par (si datele sunt numerice), mediana este media valorilor din mijlocul secventei:
  - mediana pentru {1, 3, 5, 7, 1001, 2002} este 6 (media valorilor 5 si 7).

Tendinta centrala – Valoare modala

- **Valoarea modala**: Cea mai frecventa valoare din multimea respectiva.
- Un set de date poate avea mai multe valori modale. Pentru 1, 2 si 3 setul este denumit called unimodal, bimodal sau trimodal.
- Cand fiecare valoare apare o singura data setul nu are valoare modala
- Pentru un set unimodal, valoarea modala masoara tendinta centrala a acestuia. In acest caz exista relatia empirica:

$$\text{medie} - \text{vmod} = 3 \times (\text{medie} - \text{mediana})$$

Tendinta centrala – Mijlocul intervalului

- **Mijlocul intervalului**: este media aritmetica a celei mai mari si celei mai mici valori.
- Exemplu: pentru {1, 3, 5, 7, 1001, 2002, 9999} valoarea de mijloc a intervalului este 5000 (media lui 1 si 9999).

Dispersia valorilor (1)



- **Intervalul de valori**. Este diferenta intre cea mai mare si cea mai mica valoare.
- Exemplu: for {1, 3, 5, 7, 1001, 2002, 9999} valoarea este 9999 – 1 = 9998.
- **Procentul k**. Acesta este o valoare x_j apartinand setului de date si care are proprietatea ca un procent de k valori din set sunt mai mici sau egale cu ea.
- Exemplu: Mediana este procentul 50.
- Cele mai utilizate procente sunt 25 si 75, numite si **cuartile** (eng. Quartiles). Notatie: Q1 pentru 25% and Q3 pentru 75%).

Dispersia valorilor (2)

- **Intervalul intre cuartile** (eng. Interquartile range sau IQR) este diferenta intre Q3 si Q1:

$$IQR = Q3 – Q1$$

- Potentialele puncte izolate (outliers) sunt valori la distanta de cel putin 1.5 x IQR sub Q1 sau peste Q3.
- **Sumarul de 5 numere**. Uneori mediana si cuartilele nu sunt suficiente pentru a reprezenta dispersia valorilor. In acest caz adaugam si valoarea minima si maxima din setul de date:
- (Min, Q1, Median, Q3, Max) este ceea ce se numeste sumarul de 5 numere (eng. five-number summary).

Dispersia valorilor (3)



❑ **Exemple:**

Pentru {1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11}
Interval de valori = 10; Mijloc interval = 6;
Q1 = 3; Q2 = 6; Q3 = 9; IQR = 9 - 3 = 6

Pentru{1, 3, 3, 4, 5, 6, 6, 7, 8, 8}
Interval de valori = 7; Mijloc interval = 5.5;
Q1 = 3; Q2 = 5.5 [=(5+6)/2]; Q3 = 7; IQR = 7 - 3 = 4

Pentru{1, 3, 5, 7, 8, 10, 11, 13}
Interval de valori = 12; Mijloc interval = 7;
Q1 = 4; Q2 = 7.5; Q3 = 10.5; IQR = 10.5 - 4 = 6.6

Dispersia valorilor (4)

- **Deviatia standard** (abaterea standard). Pentru n valori (observati) aceasta este:

$$\sigma = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(x_i - \mu)^2}, \quad \text{where} \quad \mu = \frac{1}{N}\sum_{i=1}^{N} x_i.$$

- Patratul deviatiei standard se numeste **varianță** (dispersie)
- Deviatia standard masoara raspandirea valorilor in jurul valorii medii.
- Valoarea 0 este obtinuta doar daca toate valorile sunt egale.

Preprocesarea datelor

- Tipuri de date
- Masurarea datelor
- Curatarea datelor
- Integrarea datelor
- Transformarea datelor
- Reducerea datelor
- Discretizarea datelor

Curatarea datelor

- Obiectivele principale ale acestei etape sunt:
  - Inlocuirea (sau eliminarea) valorilor lipsa
  - Netezirea zgomotului
  - Eliminarea sau doar identificarea punctelor izolate (eng.: outliers - valori aberante)

Valori lipsa

- Anumite atribute pot contine valori lipsa / valori nule (NULL).
- Pot sa apara din diverse motive:
  - Probleme hardware, software sau erori ale operatorului de introducere date
  - Date care nu au fost colectate intr-o anumita perioada (nu au fost considerate importante)
  - Valori eliminate pentru ca erau inconsistente cu restul
- Exista doua solutii in acest caz:

1. Ignorarea liniilor din tabela de date de intrare care contin valori lipsa. Asta se poate face doar in cazul in care numarul lor este mic si eliminarea nu induce erori in calculele ulterioare.

Valori lipsa



2. Inlocuirea valorilor lipsa cu alte valori. Posibilitati:

- Completarea manuala a valorilor. Solutia nu este viabila in cazul seturilor de date mari
- Inlocuirea cu o valoare nenula de tip 'Necunoscut' sau 'Indisponibil'.
- Inlocuirea cu o valoare care masoara tendinta centrala a acelui atribut (medie, mediana, valoare modala).
- Inlocuirea cu o valoare care masoara tendinta centrala dar doar a unui subset (exemplele apartinand aceleiasi clase pentru seturi etichetate).
- Cea mai probabila valoare, calculata cumva (arbori de decizie, etc.)

Netezire zgomot

- Zgomotul poate fi definit ca o eroare aleatoare sau variatie pentru o valoare masurata ([Han, Kamber 06])
- Pentru eliminarea zgomotului se pot folosi diverse tehnici de netezire ca:
  - Regresia (prezentata mai devreme)
  - Binning = Partitionarea in transe

Binning

- Aceasta tehnica poate fi folosita pentru netezirea unui set ordonat de valori. Este bazata pe valorile din vecinatate.
- Sunt 2 pasi:

1. Partitionarea setului ordonat in mai multe transe
2. Netezirea fiecarei transe de date pe baza mediei, medianei sau capetelor intervalului.

Exemplu

- Fie urmatorul set ordonat de valori: 1, 2, 4, 6, 9, 12, 16, 17, 18, 23, 34, 56, 78, 79, 81:

Transele initiale	Se utilizeaza media	Se utilizeaza mediana	Se utilizeaza capetele intervalului
1, 2, 4, 6, 9	4, 4, 4, 4, 4	4, 4, 4, 4, 4	1, 1, 1, 9, 9
12, 16, 17, 18, 23	17, 17, 17, 17, 17	17, 17, 17, 17, 17	12, 12, 12, 23, 23
34, 56, 78, 79, 81	66, 66, 66, 66, 66	78, 78, 78, 78, 78	34, 34, 81, 81, 81

Rezultat



Rezultatul netezirii este:

- Initial: 1, 2, 4, 6, 9, 12, 16, 17, 18, 23, 34, 56, 78, 79, 81
- Cu medie: 4, 4, 4, 4, 4, 17, 17, 17, 17, 17, 66, 66, 66, 66, 66
- Cu mediana: 4, 4, 4, 4, 4, 17, 17, 17, 17, 17, 78, 78, 78, 78, 78
- Cu capetele intervalului: 1, 1, 1, 9, 9, 12, 12, 12, 23, 23, 34, 34, 81, 81, 81

Puncte izolate

- Punctele izolate / valorile aberante (outliers) sunt valori numerice de atribut aflate la distanta mare de restul datelor.
- Uneori sunt valori corecte: salariul unui CEO poate fi mult mai mare decat al restului angajatilor.
- De cele mai multe ori insa sunt date eronate / zgomot.
- Trebuie identificate si eliminate sau inlocuite, deoarece multi algoritmi sunt sensibili la astfel de puncte – de exemplu k-means da clustere eronate in prezenta lor.

Identificare puncte izolate

- Folosind IQR: am mai spus ca potentiale puncte izolate (outliers) sunt valorile aflate la o distanta de cel putin 1.5 * IQR sub Q1 sau peste Q3.
- Folosind deviatia standard: valorile care sunt la distanta mai mare de 2σ de valoarea medie sunt potentiale valori izolate.
- Folosind clustering: Dupa gasirea clusterelor, punctele aflate in afara oricarui cluster (sau foarte departate de orice centru de cluster) sunt potentiale puncte izolate.

Preprocesarea datelor

- Tipuri de date
- Masurarea datelor
- Curatarea datelor
- Integrarea datelor
- Transformarea datelor
- Reducerea datelor
- Discretizarea datelor

Integrarea datelor

- Dupa ce datele provenind din sursele de date individuale au fost curatate ca mai inainte, are loc integrarea acestora intr-un unic ansamblu de date.
- Activitatile din aceasta categorie includ:

1. **Integrarea schemelor**. Problemele sunt de tip sinonime (acelasi lucru apare in doua surse cu nume diferite) si omonime (cu acelasi nume se gasesc date de tip diferit in diverse surse).
2. **Duplicate si redundanta**. In surse diferite se regasesc aceleasi informatii. Duplicatele si redundanta trebuie eliminate in aceasta faza.

Integrarea datelor

3. **Inconsistente**.

- Acestea sunt valori aflate in conflict in acelasi set de date.
- De exemplu Data nasterii='1.1.1980' si Varsta=30 pentru o aceeasi persoana reprezinta o inconsistenta.
- Pentru detectarea acestora sunt necesare informatii suplimentare despre date.

Preprocesarea datelor

- Tipuri de date
- Masurarea datelor
- Curatarea datelor
- Integrarea datelor
- Transformarea datelor
- Reducerea datelor
- Discretizarea datelor

Transformarea datelor



- Aceasta etapa cuprinde procese de transformare si sumarizare a datelor ca:
  - Normalizare
  - Constructie de noi atribute
  - Sumarizare folosind functiile statistice

Normalizare

- Toate atributele numerice sunt scalate pentru a avea valori intr-un acelasi interval specificat:
  - De la 0 la 1,
  - De la -1 la 1 sau, mai general:
  - |v| <= r unde r este o valoare specificata.
- Normalizarea este necesara cand anumite atribute sunt mai importante decat altele doar pentru ca plaja lor de valori este mai intinsa.
- Exemplu: Distanta euclidiana intre A(0.5, 101) si B(0.01, 2111) este ≈ 2010, determinata aproape exclusiv pe baza celei de-a doua coordonate.

Normalizare

Putem folosi pentru normalizare:

- **Normalizarea min-max:**

$$vnew = (v - vmin) / (vmax - vmin)$$

- **Pentru valori pozitive** putem folosi formula:

$$vnew = v / vmax$$

- **Normalizarea de tip z-score** (σ este deviatia standard):

$$vnew = (v - vmean) / \sigma$$

- **Scalarea zecimala**:

$$vnew = v / 10^n$$

Unde n e cel mai mic intreg pentru care toate numerele devin in modul mai mic decat o valoare data r (de exemplu r=1).

Constructie noi atribute

- Este o tehnica prin care se adauga noi atribute (in engleza se numeste **feature construction**).
- Exemplu: daca setul de date are un atribut Culoare cu valorile {Rosu, Verde, Albastru} putem construio 3 noi atribute numite Rosu, Verde, Albastru continand doar valori binare (0 sau 1) cu 1 singur 1 pe atributul (coloana) corespunzatoare culorii curente.
- Alt exemplu: se poate utiliza un arbore de decizie sau set de reguli pentru a construi noi atribute din cele existente – ca de exemplu clasa.

Sumarizare

- Se folosesc functii statistice (min, max, sum, avg, count, etc) pentru a adauga date sumare datelor originale.
- Exemplu: se adauga suma vanzarilor pe zi sau luna sau an, numarul mediu sau total de clienti sau tranzactii, etc.
- Aceste date vor fi folosite pentru cresterea vitezei de procesare a unore cereri in procesul de data mining.
- Rezultatul este un cub de date si fiecare data sumara este atasata unui nivel de granularitate.

Preprocesarea datelor

- Tipuri de date
- Masurarea datelor
- Curatarea datelor
- Integrarea datelor
- Transformarea datelor
- Reducerea datelor
- Discretizarea datelor

Reducerea datelor

- Nu toate informatiile colectate sunt necesare pentru anumite analize asupra datelor.
- Reducerea inseamna extragerea unui parti din datele colectate si preprocesate, si anume doar a acelei parti care contine informatiile necesare procesului de analiza respectiv.
- Se realizeaza de exemplu prin selectarea doar a anumitor atribute (coloane) sau exemple (linii) din matricea de date supusa analizei.

Discretizare



- Anumiti algoritmi sunt conceputi pentru analiza datelor discrete.
- Pentru a ii folosi, este necesar ca valorile continue sa fie inlocuite cu unele discrete.
- De exemplu Varsta care are valori numerice va fi inlocuita cu un atribut categoric avand doar valorile Copil, Adult, Batran.
- Exista diverse metode de a efectua operatia de discretizare, folosind impartirea in transe (binning), histograme, intervale bazate pe entropie, clustering, ierarhii de concepte, etc.

Sumar



In acest curs am prezentat:

- O lista de definitii alternative pentru Data Mining si cateva exemple pentru a intelege ce este Data Mining si ce nu este Data Mining.
- O discutie despre comunitatile implicate in Data Mining si despre faptul ca Data Mining este de fapt o reuniune heterogena de subdomenii.
- Pasii procesului de Data Mining process de la colectarea datelor aflate in locatii diferite (depozite de date, arhive sau sisteme operationale) pana la pasul final de evaluare
- O scurta descriere a subdomeniilor principale ale Data Mining cu exemple pentru fiecare dintre ele.
- O descriere cuprinzatoare a procesului de preprocesare a datelor.

Lectia viitoare: Multimi frecvente de articole si reguli de asociere

Bibliografie si referinte

- [Liu 11] Bing Liu, 2011. Web Data Mining, Exploring Hyperlinks, Contents, and Usage Data, Second Edition, Springer, 1-13.
- [Tan, Steinbach, Kumar 06] Pang-Ning Tan, Michael Steinbach, Vipin Kumar, 2006. Introduction to Data Mining, Adisson-Wesley, 1-16.
- [Kimbal, Ross 02] Ralph Kimball, Margy Ross, 2002. The Data Warehouse Toolkit, Second Edition, John Wiley and Sons, 1-16, 396
- [Mikut, Reischl 11] Ralf Mikut and Markus Reischl, Data mining tools, 2011, Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery, Volume 1, Issue 5, http://onlinelibrary.wiley.com/doi/10.1002/widm.24/pdf
- [Ullman] Jeffrey Ullman, Data Mining Lecture Notes, 2003-2009, web page: http://infolab.stanford.edu/~ullman/mining/mining.html
- What is the difference between data mining, statistics, machine learning and AI? http://stats.stackexchange.com/questions/5026/what-is-the-difference-between-data-mining-statistics-machine-learning-and-ai

Bibliografie si referinte

- Akash Mitra, Data Mining - a simple guide for beginners, 2012, http://www.dwbiconcepts.com/data-warehousing/11-data-mining/97-data-mining-for-beginners.html
- [Wikipedia] Wikipedia, the free encyclopedia, en.wikipedia.org
- [Han, Kamber 06] Jiawei Han, Micheline Kamber, Data Mining: Concepts and Techniques, Second Edition, Morgan Kaufmann Publishers, 2006, 47-101
- [Stevens 46] Stevens, S.S, On the Theory of Scales of Measurement. Science June 1946, 103 (2684): 677–680.
- [Wikipedia] Wikipedia, the free encyclopedia, en.wikipedia.org
- [Liu 11] Bing Liu, 2011. CS 583 Data mining and text mining course notes, http://www.cs.uic.edu/~liub/teach/cs583-fall-11/cs583.html